ACH2036 - Métodos Quantitativos para Análise Multivariada

Atividade 1 - Modelos de Regressão: Análise de resíduos e transformações de escala

Versão do enunciado: 25/09

1 Objetivo

O objetivo desta atividade é:

- Consolidar alguns dos conceitos e técnicas sobre Regressão Linear Simples apresentados nas Seções 1, 2, 3 e 4 do material didático (https://online.stat.psu.edu/stat501/);
- Exercitar a análise exploratória de dados;
- Exercitar o diagnóstico do ajuste da regressão através da análise de resíduos;
- Explorar o uso de transformações de escalas nas variáveis para a obtenção de melhores ajustes da regressão.

2 *Datasets* a serem analisados

1. **Treadwear**:
   - Detalhes na Seção 4
   - Variável resposta (Y): `groove`
   - Variável preditora (X): `mileage`
2. **Alligators**:
   - Detalhes na Seção 4
   - Variável resposta (Y): `weight`
   - Variável preditora (X): `length`
3. **ConcPatog.txt**:
   - Este conjunto de dados contém concentrações de dois patógenos em água de esgoto tratado. Essas concentrações foram medidas sob diferentes estações de tratamento, estágios de tratamento e meses do ano.
   - O interesse é saber se é possível ajustar um modelo de regressão que permita estimar, com razoável acurácia, a concentração do patógeno 2 a partir da concentração do patógeno 1.
   - Disponível no subdiretório *datasets* do Drive compartilhado ACH2036_2026. Arquivo texto separado por tabulações.
   - Variável resposta (Y): `CPatog2`
   - Variável preditora (X): `CPatog1`

3 Etapas da análise:

Para cada um dos *datasets*, você deverá realizar as seguintes etapas:

1. Plotar um gráfico de dispersão entre a variável resposta (eixo vertical) e a variável preditora (eixo horizontal).

   Comente sobre o gráfico: existe indício visual de associação linear entre as variáveis? Se não, que fenômenos você observa em termos da tendência, concentrações dos pontos, dispersão, etc.

2. Ajustar um modelo de regressão linear simples entre a variável preditora e a variável resposta, exibindo os seguintes resultados:

   - Tabela geral dos resultados do ajuste, conforme exemplo apresentado no Notebook SLR_Hospital_Infection.ipynb (ver figura abaixo).

OLS Regression Results

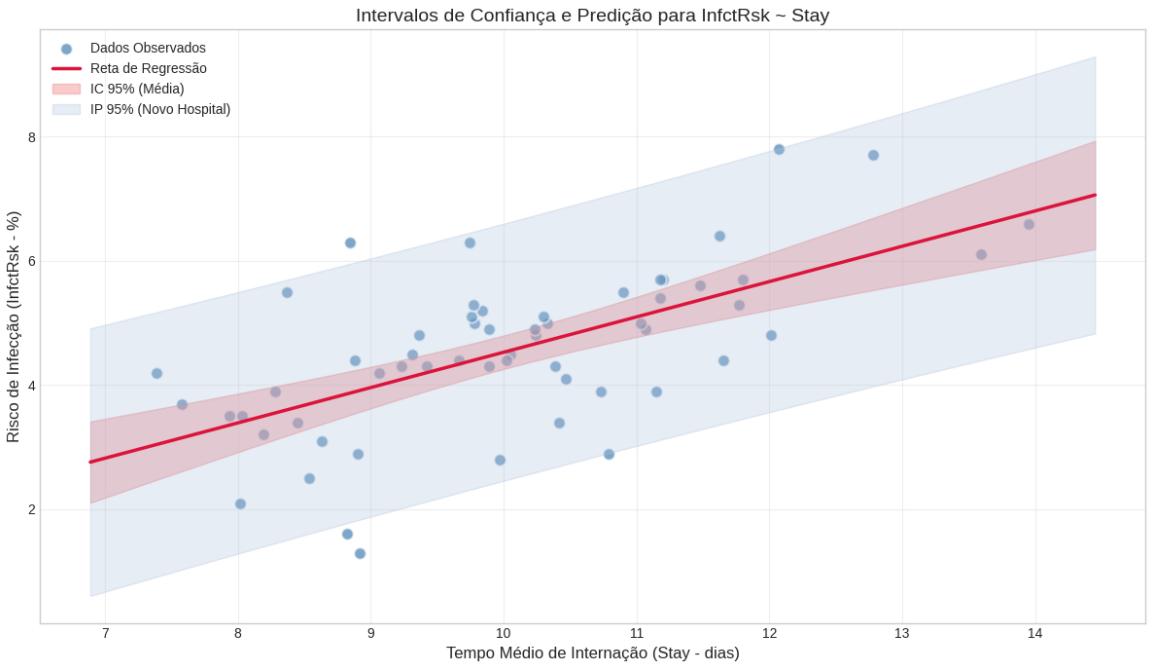
Dep. Variable:	InfctRsk	R-squared:	0.395
Model:	OLS	Adj. R-squared:	0.384
Method:	Least Squares	F-statistic:	36.50
Date:	Fri, 25 Sep 2026	Prob (F-statistic):	1.30e-07
Time:	20:45:26	Log-Likelihood:	-82.684
No. Observations:	58	AIC:	169.4
Df Residuals:	56	BIC:	173.5
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	-1.1598	0.956	-1.213	0.230	-3.075	0.755
Stay	0.5689	0.094	6.041	0.000	0.380	0.757

Omnibus:	1.579	Durbin-Watson:	2.075
Prob(Omnibus):	0.454	Jarque-Bera (JB):	0.839
Skew:	-0.170	Prob(JB):	0.657
Kurtosis:	3.481	Cond. No.	72.8

   Comentar o valor do R^2 ajustado. Com base neste indicador, é possível afirmar que o modelo captura bem a variabilidade da variável resposta?

   - Gráfico de dispersão incluindo a reta da regressão, intervalo de confiança e intervalo de predição. Você pode aproveitar o código do Notebook citado acima. Exemplo:



- Apresente os seguintes gráficos dos resíduos:
  - Histograma dos resíduos (com a respectiva densidade sob a distribuição normal, se possível)
  - Gráfico dos resíduo vs. valores preditos
  - QQ-plot dos resíduos usando a distribuição normal como referência

  Com base nesses gráficos, as premissas **LINE** (**L**inear function, **I**ndependent errors, **N**ormal distribution, **E**qual variance) são satisfeitas? Comente quais dessas premissas parecem válidas e quais parecem violadas.

3. Agora, você deverá testar diferentes transformações sobre X ou sobre Y:

   - Raiz quadrada (somente sobre X, somente sobre Y ou sobre ambas)
   - Quadrado (somente sobre X, somente sobre Y ou sobre ambas)
   - Logaritmo na base 10 (somente sobre X, somente sobre Y ou sobre ambas). Embora o logaritmo natural seja bastante utilizado, eu tendo a preferir o log10 por ser mais fácil de interpretar

4. Para cada uma dessas nove possibilidades, plote o gráfico de dispersão sobre as variáveis transformadas. Escolha a combinação de transformações cujo gráfico de dispersão indique a melhor associação linear entre a variável resposta e a variável preditora (com suas respectivas transformações).

5. Para a combinação escolhida, apresente o gráfico de dispersão (item 1) e os resultados do ajuste da regressão (item 2), com as mesmas saídas e respectivas discussões.

4 Formato e prazo para entrega

- Deverá ser entregue um relatório em formato PDF. Não incluir seus códigos Python.
- O relatório pode ser feito em duplas (não necessariamente da mesma turma).
- A entrega deverá ser feita exclusivamente através do e-disciplinas.

- **Prazo para entrega: 06/10**